Factor Investing with a Deep Multi-Factor Model: Implementation in KOSPI Market

박사홍 Sahong Park
Hankuk University of Foreign Studies
Division of Finance & AI

우민주 Minju Woo
Hankuk University of Foreign Studies
Department of Mathematics

본 연구는 Deep Multi-Factor Model (DMFM)을 한국 주식 시장(KOSPI)에 적용하여, 해당 모델의 예측 성능과 투자 성과를 실증적으로 분석한다. 전통적인 선형 다요인 자산가격 모형은 해석 가능성과 단순성이라는 장점을 지니지만, 팩터 간 비선형 상호작용과 시장 구조적 요인을 충분히 반영하지 못하는 한계를 가진다. 최근 딥러닝 기반 팩터 모델이 이러한 한계를 보완하고자 제안되었으나, 산업 및 시장 수준의 공통 요인을 효과적으로 분리하지 못할 경우 성과의 불안정성이 발생할 수 있다.

DMFM은 비선형 컨텍스트 학습과 그래프 어텐션 네트워크를 결합하여, 산업 및 시장 수준에서 발생하는 구조적 영향을 단계적으로 제거함으로써 종목 고유의 알파 신호를 추출하도록 설계된 모델이다. 본 연구에서는 KOSPI 상장 종목을 대상으로 기술적 및 기본적 팩터를 구성하고, DMFM을 포함한 다양한 베이스라인 모델들과의 비교 실험을 수행하였다. 성과 평가는 Information Coefficient(IC), ICIR, Sharpe Ratio, 연환산 수익률, 최대 낙폭(Max Drawdown) 등 예측 정확도와 경제적 유의성을 동시에 고려한 지표를 통해 이루어졌다.

실험 결과, DMFM은 거래 비용을 반영한 기준에서도 가장 높은 Net Sharpe Ratio와 연환산 수익률을 기록하였으며, 기간별 분석에서도 안정적인 성과를 유지하였다. 이러한 결과는 DMFM의 산업 및 시장 중립화 구조가 한국 주식 시장에서도 효과적으로 작동함을 보여주며, 해당 모델이 다양한 시장 환경에서도 실무적으로 활용 가능한 딥러닝 기반 팩터 모델임을 시사한다.

I. Introduction

다요인 자산 가격 모형은 주식 수익률을 설명하고 예측하기 위한 핵심적인 도구로 오랜 기간 활용되어왔다. 대표적으로 Fama-French 계열의 선형 팩터 모델은 가치, 규모, 모멘텀과 같은 소수의 공통 팩터를 통해 자산 수익률의 횡단면을 설명하고자 하였으며, 이론적 해석 가능성과 실무적 단순성이라는 장점을 지닌다. 그러나 이러한 전통적 다요인 모델은 팩터와 수익률 간의 선형성, 팩터 간 독립성, 그리고 모든 종목이 동일한 팩터 구조를 공유한다는 강한 가정에 기반하고 있으며, 실제 금융 시장에서는 이러한 가정이 반복적으로 위배되는 것이 관찰된다.

특히 금융 시장에서는 팩터 프리미엄이 시기에 따라 변화하며, 특정 임계 수준에서 급격한 반응을 보이는 비선형적 특성이 빈번하게 나타난다. 또한 가치, 모멘텀, 퀄리티와 같은 팩터들은 독립적으로 작용하기보다는 서로 얽힌 형태로 나타나며, 특정 팩터에 대한 과도한 노출은 오히려 리스크를 증폭시키는 결과를 초래하기도 한다. 이러한 이유로 전통적인 선형 팩터 모델은 설명력과 예측력 측면에서 구조적인 한계를 지닌다.

이러한 문제의식을 바탕으로 최근 연구들은 딥러닝 기법을 활용하여 팩터와 수익률 간의 비선형 관계와 복잡한 상호작용을 학습하려는 방향으로 확장되어 왔다. 다층 퍼셉트론과 같은 신경망 기반 모델은 기존 선형 모델보다 높은 표현력을 제공하며, 실제로 일부 연구에서는 예측 성능의 개선을 보고하고 있다. 그러나 딥러닝 기반 팩터 모델은 구조가 복잡해질수록 해석 가능성이 저하되고, 종목 간의 구조적 관계를 충분히 반영하지 못하는 경우가 많다는 한계를 함께 지닌다.

이러한 맥락에서 Deep Multi-Factor Model(DMFM)은 딥러닝의 비선형 학습 능력과 그래프 신경망을 결합하여, 전통적 팩터 모델의 한계를 체계적으로 보완하려는 시도로 제안되었다. DMFM은 원본 팩터로부터 비선형 컨텍스트를 학습한 뒤, 산업 수준과 시장 전체 수준에서의 구조적 영향을 그래프 어텐션 네트워크를 통해 명시적으로 추정하고 제거한다. 이를 통해 종목 고유의 특성을 단계적으로 정제하며, 예측력뿐만 아니라 팩터의 안정성과 해석 가능성을 동시에 고려한 학습 목적 함수를 통해 실무적 활용 가능성을 높이고자 한다.

기존 논문에서는 DMFM을 중국 주식 시장에 적용하여, CSI300, CSI500, CSI1000과 같은 대형 주식 유니버스에서 기존 선형 모델 및 딥러닝 기반 베이스라인 대비 우수한 성과를 보고하였다(Wei, Dai, & Lin, 2022). 그러나 금융 시장은 국가별로 산업 구조, 투자자 구성, 규제 환경, 데이터 특성이 상이하며, 이러한 차이는 팩터 프리미엄의 형성과 지속성에 직접적인 영향을 미친다. 따라서 특정 시장에서의 성과만으로 모델의 일반화 가능성을 단정하기는 어렵다.

한국 주식 시장은 상대적으로 높은 변동성과 함께 특정 시기마다 팩터 성과의 불안정성이 두드러지는 특징을 지닌다. 또한 산업 분류 체계, 재무 데이터의 공시 주기, 거래 비용 구조 등은 중국 시장과 명확한 차이를 보인다. 이러한 환경에서는 DMFM이 제안하는 산업 및 시장 중립화 구조가 실제로 유효하게 작동하는지에 대한 별도의 검증이 필요하다.

이에 본 보고서는 기존 DMFM 논문을 바탕으로, 한국 주식 시장을 대상으로 한 재현 실험을 수행하고 그 결과를 분석한다. 구체적으로는 KOSPI 상장 종목을 대상으로 재무 및 기술적 팩터를 재구성하고, 산업 분류 정보를 활용하여 그래프 구조를 정의한 뒤, 논문에서 제

안한 DMFM 구조를 동일하게 적용한다. 이를 통해 DMFM이 한국 시장에서도 안정적이고 일관된 팩터를 생성할 수 있는지를 실증적으로 평가한다.

본 보고서의 목적은 DMFM이 상이한 시장 환경에서도 그 구조적 강점을 유지할 수 있는지를 검증함으로써, 해당 모델의 일반화 가능성과 실무적 활용 가능성을 평가하는 데 있다. 특히 단순한 수익률 비교를 넘어 IC, ICIR, Sharpe Ratio, Max Drawdown과 같은 위험 조정 성과 지표를 함께 분석함으로써, DMFM이 장기적으로도 견고한 팩터를 생성하는지를 종합적으로 살펴본다.

이후 장에서는 먼저 DMFM의 구조와 핵심 아이디어를 간략히 정리한 뒤, 한국 시장 재현 실험의 데이터 구성과 실험 설계를 설명하고, 실증 결과를 바탕으로 DMFM의 성과와 한계를 분석한다.

Ⅱ. Methodology

본 장에서는 한국 주식 시장을 대상으로 수행한 Deep Multi-Factor Model(DMFM) 재현 실험의 방법론을 설명한다. 본 실험은 기존에 제안된 DMFM 프레임워크를 기반으로 하되, 한국 시장 데이터에 맞게 동일한 구조를 구현하여 그 일반화 가능성을 검증하는 것을 목표로 한다. 따라서 방법론 설명은 본 실험에서 실제로 사용한 모델 구성과 처리 절차를 중심으로 서술하며, 각 설계 선택이DMFM의 원래 의도와 어떻게 연결되는지를 함께 명시한다.

Ⅱ-1. Overview of the DMFM Framework

본 실험에서 사용한 DMFM은 종목의 원본 스타일 팩터로부터 비선형 컨텍스트를 학습한 뒤, 산업 수준과 시장 전체 수준에서의 구조적 공통 요인을 단계적으로 제거하고, 서로 다른 정제 수준의 정보를 결합하여 최종적인 딥 팩터를 생성하는 구조를 가진다. 이러한 계층적 구조는 전통적인 선형 팩터 모델이나 단일 딥러닝 모델과 달리, 공통 요인 제거와 비선형 학습을 동시에 수행할 수 있도록 설계되어 있다.

전체 파이프라인은 (1) Stock Context Encoder를 통한 종목별 컨텍스트 학습, (2) Industry Graph 기반 산업 중립화, (3) Universe Graph 기반 시장 중립화, (4) Deep Factor 구성, (5) 안정성과 예측력을 동시에 고려한 학습 목표 설정의 다섯 단계로 구성된다. 본 실험에서는 이 구조를 그대로 유지하여 한국 주식 시장에 적용하였다.

Ⅱ-2. Stock Context Encoder

본 실험의 첫 단계는 Stock Context Encoder로, 개별 종목의 다양한 스타일 팩터로부터 비선형적인 종목 컨텍스트를 추출하는 역할을 수행한다. 각 시점 t에서 입력 행렬 F_t은 다수의 종목에 대해 여러 개의 스타일 팩터 값으로 구성된다. 본 실험에서는 한국 주식 시장의 특성을 반영하여 기술적 팩터와 재무적 팩터를 함께 사용함으로써, 단일 유형의 정보에 대한 의존을 피하고자 하였다.

원본 팩터들은 서로 다른 단위와 분포를 가지므로, 모델 학습의 안정성을 확보하기 위해 각 팩터에 대해 정규화 과정을 먼저 적용한다. 이 정규화는 금융 실무에서 널리 사용되는

z-score 정규화와 유사한 의미를 가지며, 팩터 간 상대적 비교 가능성을 확보하는 역할을 한다. 이후 정규화된 팩터 입력은 다층 퍼셉트론(MLP)을 통과하며, 이를 통해 팩터 간의 비선형 관계와 상호작용이 잠재 공간에서 학습된다.

이 과정을 통해 생성된 출력 C_t는 원본 팩터 정보를 압축한 종목별 잠재 표현으로, 이후 산업 및 시장 중립화 단계의 입력으로 사용된다. 즉, Stock Context Encoder는 단순한 차원 축소가 아니라, 비선형 팩터 구조를 반영한 종목 컨텍스트를 생성하는 핵심 모듈이다.

II-3. Industry Graph Construction and Industry Neutralization

동일 산업에 속한 종목들이 유사한 경제 환경과 리스크 요인에 동시에 노출되는 경향이 강하다. 이러한 산업 효과를 명시적으로 제거하기 위해, 본 실험에서는 산업 분류 정보를 기반으로 Industry Graph를 구성하였다.

각 종목은 하나의 노드로 정의되며, 동일 산업에 속한 종목들 간에는 연결이 존재하도록 인접 행렬을 구성한다. 시점 t에서의 산업 마스크 행렬 $M_{i,j}^t$는 두 종목이 동일 산업에 속할 경우 1, 그렇지 않을 경우 0으로 정의된다. 이 그래프 구조 위에 Graph Attention Network(GAT)를 적용함으로써, 동일 산업 내에서 종목 간 상대적인 영향력이 데이터 기반으로 학습된다.

GAT를 통해 계산된 산업 영향 표현 H_I^t는 Stock Context Encoder의 출력 C_t에서 차감된다. 이를 통해 산업 공통 요인이 제거된 산업 중립 컨텍스트 $\overline{C}_I^t = C_t - H_I^t$가 생성된다. 이 과정은 단순한 산업 더미 변수 제거와 달리, 산업 내부에서 종목 간 영향력이 균질하지 않다는 점을 반영할 수 있다는 특징을 가진다. 본 실험에서는 이러한 산업 중립화 구조를 통해 종목 고유 특성이 산업 효과에 의해 가려지는 문제를 완화하고자 하였다.

II-4. Universe Graph Construction and Universe Neutralization

산업 중립화 이후에도 시장 전체 차원에서 공유되는 공통 요인은 여전히 존재할 수 있다. 금리 변화, 거시 경제 이벤트, 시장 전반의 위험 선호 변화와 같은 요인은 산업을 초월하여 모든 종목에 영향을 미친다. 이를 제거하기 위해 Universe Graph를 추가로 구성하였다.

Universe Graph에서는 모든 종목이 서로 연결된 완전 그래프 구조를 가정한다. 산업 중립 컨텍스트 $\overline{C}_I^t$를 입력으로 다시 한번 GAT를 적용함으로써, 시장 전체에서 공유되는 영향 H_U^t를 추정한다. 이후 이를 산업 중립 컨텍스트에서 차감하여 시장 중립 컨텍스트 $\overline{C}_U^t = \overline{C}_I^t - H_U^t$를 생성한다.

이러한 Universe Neutralization 과정은 전통적인 market-neutral 접근을 확장한 형태로 이해할 수 있다. 단순한 선형 베타 제거가 아니라, 종목 간 구조적 관계를 학습한 뒤 공통 요인을 제거한다는 점에서 차별성을 가진다. 본 실험에서는 이 구조를 통해 시장 전체의 단기적 변동성이나 공통 충격에 대한 과도한 노출을 줄이고자 하였다.

II-5. Deep Factor Construction

산업 및 시장 중립화 과정을 거친 후, 본 실험에서는 서로 다른 정제 수준의 정보를 모두 활용하여 최종적인 Deep Factor를 생성한다. 구체적으로, 원본 컨텍스트 C_t, 산업 중립 컨텍스트 $\overline{C}_I^t$, 시장 중립 컨텍스트 $\overline{C}_U^t$를 하나의 벡터로 결합(concatenation)한다.

이 결합된 입력은 선형 변환과 비선형 활성 함수(LeakyReLU)를 거쳐 최종적인 Deep Factor f_t로 변환된다. 이러한 구성의 핵심은 공통 요인 제거 이전의 정보와 제거 이후의 정보를 동시에 활용함으로써, 정보 손실을 최소화하면서도 노이즈 제거 효과를 유지할 수 있다는 점이다. 본 실험에서는 이 계층적 컨텍스트 결합 구조를 통해 보다 안정적이고 해석 가능한 팩터를 생성하고자 하였다.

Ⅱ-6. Training Objective

기존 논문에서 Deep Factor가 단순히 높은 예측력을 갖는 것에 그치지 않고, 시간에 따라 안정적인 특성을 유지하도록 학습 목표를 설정하였다. 이를 위해 수익률 설명력, 불필요한 베이스라인 효과의 분리, 그리고 팩터의 시간적 안정성을 동시에 고려하는 학습 목적을 채택하였다.

이러한 학습 목표는 특정 시점에만 과도하게 반응하는 불안정한 신호의 생성을 방지하고, 장기적으로 일관된 성과를 보이는 팩터를 유도하는 데 목적이 있다. 특히 변동성이 큰 한국 주식 시장 환경에서는 팩터의 안정성이 실무적 활용 가능성을 좌우하는 중요한 요소이므로, 본 실험에서는 이러한 점을 고려하여 DMFM의 학습 철학을 그대로 유지하였다.

Ⅲ. Experiment Setup

Ⅲ-1. Data and Features

Table 1

Data Description

항목	값
데이터셋	KOSPI (개별 종목 시계열)
종목 수	934 (전체 KOSPI 샘플)
기간	약 3000 거래일 (2013-2025)
산업 분류	79개 산업
전진 수익률	3, 5, 10, 15, 20일

본 연구는 KOSPI 상장 개별 종목 시계열 데이터를 활용하여 실험을 수행하였다. 전체 표본은 약 934개 종목으로 구성되며, 분석 기간은 2013년부터 2025년까지 약 3,000 거래일에 해당한다. 데이터는 일별 주가 및 거래량 정보를 기반으로 구축되었으며, 장기간에 걸친 시장 국면 변화(상승・하락・횡보)를 모두 포함하도록 설계되었다.

데이터는 시계열 누수를 방지하기 위해 시간 순서 기준 분할을 적용하였다. 전체 데이터를 학습(train) 60%, 검증(validation) 20%, 테스트(test) 20%로 분할하였으며, 테스트 구간에 대해

서는 추가적으로 EARLY(50-70%), MIDDLE(60-80%), RECENT(80-100%)의 세부 기간 분절을 적용하여 모델 성과의 시기별 안정성을 함께 검증하였다.

또한 본 연구는 단일 예측 지평선에 국한되지 않고, 3·5·10·15·20일 전진 수익률(forward return)을 동시에 생성하여 다중 horizon 관점에서 예측 성능을 평가하였다. 최종 포트폴리오 평가는 실무적 활용도를 고려하여 5일 보유 후 리밸런싱을 기준으로 수행하였다.

모델 입력 변수는 총 27개의 팩터로 구성되며, 크게 기술적 팩터 21개와 기본적/팩터 기반 변수 6개로 구분된다. 기술적 팩터는 가격과 거래량의 시계열적 특성을 포착하는 데 초점을 두고 설계되었으며, 기본적 팩터는 기업 가치 및 위험 요인을 반영하도록 구성되었다.

기술적 팩터에는 모멘텀(Momentum), 단기·중기 반전(Reversal), 변동성(Volatility), 거래량 및 유동성(Volume), 이동평균 및 추세 지표(Moving Averages) 등이 포함된다. 이를 통해 단기 가격 움직임과 시장 미시구조 정보를 동시에 반영하고자 하였다.

기본적/팩터 기반 변수에는 재무비율 및 Fama-French 스타일 팩터가 포함되어, 기업의 구조적 특성과 장기 위험 프리미엄을 함께 고려하도록 설계하였다.

모든 연속형 변수는 표준화(Standardization) 과정을 거쳤으며, 결측치는 사전에 정의된 규칙에 따라 처리하였다. 산업 분류 정보는 모델 입력에 활용 가능하도록 인코딩되어 포함되었다. 이러한 피처 구성은 단순 예측 성능뿐 아니라, 다양한 시장 국면에서도 일관된 랭킹 성능과 포트폴리오 성과를 확보하는 것을 목표로 한다.

Ⅲ-2. Baseline Models

본 연구에서 성능을 검증하고자 하는 모델인 DMFM의 성능을 객관적으로 평가하기 위해, 전통적인 팩터 기반 방법부터 신경망 기반 모델까지 다양한 baseline 모델을 함께 비교하였다. 모든 baseline 모델은 동일한 입력 피처와 실험 환경에서 학습 및 평가되었으며, 예측 결과는 동일한 Long-Short 포트폴리오 구성 규칙을 통해 성과를 측정하였다.

Table 2

Baseline Models

Model	값
OLS Factor Model	횡단면 OLS 회귀를 적용한 기본적인 선형 모델
MLP Factor Model	MLP를 활용해 비선형 관계를 학습하는 모델
MLP + GAT Model	MLP로 관계를 학습한 후 그래프 어텐션으로 상호작용 반영
Momentum Model	과거 수익률을 그대로 팩터 점수로 활용하는 추세 추종 전략
Mean Reversion Model	단기 수익률의 부호를 반전시켜 단기 반전 효과 포착

Note. Momentum, Mean Reversion Model은 학습이 필요 없는 전통적 팩터 전략임

Table 2에서 볼 수 있듯, 총 5개의 Baseline 모델들과 DMFM 모델을 비교하였다. Linear Factor Model은 입력 팩터에 대해 횡단면 OLS 회귀를 적용한 가장 기본적인 선형 모델로, 팩터와 수익률 간의 선형 관계만을 가정한다. 이는 전통적인 자산가격 모형과 가장 유사한 기준선 역할을 한다. MLP Factor Model은 다층 퍼셉트론(MLP)을 활용하여 비선형 관계를 학습하는 모델이다. 선형 모형 대비 표현력은 증가하지만, 종목 간 구조적 관계(산업·시장 전체 효과)는 명시적으로 반영하지 않는다. MLP + GAT Model은 MLP로 종목별 표현을 학습

한 뒤, 그래프 어텐션을 통해 종목 간 상호작용을 반영하는 확장 모델이다. 다만, 그래프를 통해 집계된 영향력을 제거(neutralization)하지 않고 단순히 결합(concatenation)하는 구조로 설계되어, DMFM의 핵심 요소인 “중립화 메커니즘”의 효과를 검증하기 위한 비교 기준으로 Ablation Study의 형태로 활용된다.

Ⅲ-3. Experiment Costs & Trading Assumptions

본 연구에서의 실험 결과가 실제 투자 환경에서도 의미를 가질 수 있도록, 포트폴리오 구성 및 성과 평가는 현실적인 거래 비용과 운용 가정을 반영하여 수행하였다. 모든 모델은 동일한 거래 비용 구조와 포트폴리오 규칙 하에서 비교되며, 이를 통해 모델 간 성과 차이가 비용 가정의 차이에서 기인하지 않도록 통제하였다.

거래 비용은 Commission 0.1%, Slippage 0.2%를 적용하였다. 이는 실제 주식 시장에서 발생하는 거래 수수료 및 유동성 비용을 보수적으로 반영한 값으로, 공매도 포지션에 대해서는 연 2%의 차입 비용을 고려하여, Long-Short 전략 운용 시 발생하는 추가 비용을 고려하였다.

포트폴리오는 각 평가 시점마다 예측된 팩터 점수를 기준으로 상위 10개 종목(Long)과 하위 10개 종목(Short)을 동일 비중으로 구성하는 Long-Short 전략을 사용하였다. 이를 통해 모델이 예측해서 생성하는 상대적인 랭킹 성과에 집중할 수 있도록 설계하였다.

각 포트폴리오는 5일 보유 후 리밸런싱을 기본 단위로 운용되며, 성과 평가 또한 동일하게 5일을 기준으로 산출되었다. 실험 전반에서 관측된 평균 회전율은 약 50% 수준으로, 현실적으로 발생 가능한 거래 빈도를 반영한다.

이와 같은 비용 및 거래 가정은 단순한 이론적 수익률이 아닌, 거래 비용 차감 후 순 성과 지표 (Net Sharpe Ratio, 연환산 수익률)을 모델의 실질적 투자 효용성을 평가하기 위한 목적에서 도입되었다.

Ⅲ-4. Evaluation Metrics

본 연구에서는 예측 정확도뿐만 아니라, 실제 투자 전략 관점에서 경제적 유의성을 함께 평가하게 위해 통계적 예측 지표와 포트폴리오 성과 지표를 병행하여 사용하였다.

Ⅲ-4-1. Information Coefficient (IC)

Information Coefficient (IC)는 특정 시점에서 모델이 산출한 종목별 예측 점수와 이후 실현 수익률 간의 교차 Pearson Correlation Coefficient로 식 1과 같이 정의된다.

$$IC_t = \frac{\sum_i (f_{i,t} - \bar{f}_t)(r_{i,t} - \bar{r}_t)}{\sqrt{\sum_i (f_{i,t} - \bar{f}_t)^2} \sqrt{\sum_i (r_{i,t} - \bar{r}_t)^2}} \quad \cdots \text{(식 1)}$$

IC는 모델의 랭킹 예측 능력을 측정하는 핵심 지표로, 값이 양수일수록 높은 점수를 받은 종목이 실제로 더 높은 수익을 기록했음을 의미한다.

Ⅲ-4-2. Information Coefficient Information Ratio (ICIR)

Information Coefficient Information Ratio (ICIR)는 IC의 평균을 표준편차로 나눈 값으로, 예측 성능의 안정성을 측정한다.

$$ICIR = \frac{\overline{IC}}{std(IC)} \quad \cdots \text{(식 2)}$$

식 2에서 정의된 ICIR이 높을수록 예측 성과가 특정 시점에 의존하지 않고 일관되게 나타남을 의미한다.

V-4-3. Factor Return

Factor Return은 특정 시점의 예측 점수 벡터와 실현 수익률 간의 교차섹션 회귀를 통해 계산된 OLS 계수로 식 3과 같이 정의된다.

$$b_t = \frac{f_t^\top r_t}{f_t^\top f_t} \quad \cdots \text{(식 3)}$$

이는 해당 팩터가 단기적으로 미래 수익률을 얼마나 설명하는지에 대해 나타내는 지표로, 값이 양수일 경우 팩터가 유의미한 알파 정보를 포함하고 있음을 의미한다.

V-4-4. Portfolio Return Metrics

포트폴리오 성과는 리밸런싱(5일) 단위 수익률을 누적하여 평가하였다. Total Return과 Annual Return은 다음 식 4와 같이 계산된다.

$$\begin{aligned} Total\,Return &= \prod_p (1 + R_p) - 1, \\ Annual\,Return &= (1 + Total\,Return)^{1/n_{years}} - 1 \end{aligned} \quad \cdots \text{(식 4)}$$

같은 맥락으로, 연간 변동성(Annual Volatility)은 기간별 수익률의 표준편차를 연간 기준으로 환산하여 식 5와 같이 산출하였다.

$$\sigma_{ann} = std(R_p)\sqrt{N} \quad \cdots \text{(식 5)}$$

Ⅲ-4-5. Sharpe Ratio 및 Max Drawdown

Sharpe Ratio는 우선 무위험수익률을 0으로 가정한 상태에서 연환산 수익률을 연환산 변동성으로 나눈 값으로 식 6과 같이 정의하였다.

$$SR = \frac{Annual\,Return}{\sigma_{ann}} \quad \cdots \text{(식 6)}$$

거래 비용을 반영하지 않은 값은 Sharpe (gross), 거래 비용을 차감한 순수익 기준 값은 Net Sharpe로 구분하여 결과를 산출하였다.

Max Drawdown (MDD)는 누적 수익 곡선에서 발생한 최대 손실 비율로 식 7과 같이 정의되고, 전략의 최대 위험을 평가하기 위한 지표이다.

$$MDD = \min_t \frac{C_t - \max_{s \le t} C_s}{\max_{s \le t} C_s} \quad \cdots \text{(식 7)}$$

식 6에서 C_t는 시점 t까지의 누적 포트폴리오 가치를 의미한다.

Ⅲ-4-6. Win Rate

Win Rate는 리밸런싱 기간 중 수익률이 양수인 구간의 비율로 식 8과 같이 정의된다.

$$Win\,Rate = \frac{\#\{p : R_p > 0\}}{N_{periods}} \quad \cdots \text{(식 8)}$$

식 8의 #은 그 집합에 포함된 원소의 개수, 즉 조건을 만족하는 기간의 개수를 뜻한다.

Ⅳ. Empirical Results

Ⅳ-1. Main Performance

Table 3
Main Performance (Net of Costs)

Model	IC	ICIR	Net Sharpe	Ann.Return	Ann.Vol	MDD	Win Rate
Linear	0.041	16.14	1.36	23.1%	**17.0%**	-26.3%	56.4%
Momentum	-0.019	-7.92	-1.63	-36.4%	22.4%	-93.4%	40.8%
Reversal	0.019	7.92	0.05	1.1%	22.4%	-61.0%	48.3%
MLP	**0.049**	8.34	1.80	33.0%	18.4%	-28.5%	61.7%
MLP_GAT	**0.049**	15.20	2.18	41.5%	19.0%	-32.5%	62.5%
DMFM	0.046	**18.44**	**2.73**	**52.2%**	19.1%	**-24.7%**	**66.7%**

Table 3은 거래 비용을 반영한 기준에서 각 모델의 주요 성과 지표를 비교한 결과를 제시한다. 전반적으로 DMFM은 대부분의 핵심 지표에서 가장 우수하거나 상위 수준의 성과를 기록하였다.

먼저 예측 성능 측면에서 DMFM의 평균 IC는 0.046으로, MLP 및 MLP+GAT과 유사한 수준을 유지하면서도 ICIR은 18.44로 전체 모델 중 가장 높은 값을 기록하였다. 이는 DMFM이 단순히 평균적인 예측 정확도뿐 아니라, 시간에 따른 예측 성과의 일관성 측면에서도 우수함을 의미한다.

포트폴리오 성과 측면에서는 DMFM의 우위가 더욱 뚜렷하게 나타난다. 거래 비용을 차감한 Net Sharpe Ratio는 2.73, 연환산 수익률은 52.2%로 모든 비교 모델을 상회하였다. 특히 MLP+GAT이 그래프 구조를 활용함에도 불구하고 Net Sharpe 2.18에 그친 반면, DMFM은 중립화(neutralization)를 포함한 구조적 설계를 통해 추가적인 성과 개선을 달성하였다.

리스크 측면에서도 DMFM은 비교적 안정적인 특성을 보인다. 최대 낙폭(MDD)은 -24.7%로, Linear, MLP, MLP+GAT 대비 낮은 손실 폭을 기록하였으며, Win Rate 또한 66.7%로 가장 높아 수익 발생 빈도 측면에서도 우수한 성과를 보였다. 이는 DMFM이 극단적인 일부 구간에 의존하지 않고, 전반적으로 안정적인 알파를 생성하고 있음을 시사한다.

IV-2. Period-wise Performance Analysis

Table 4
Period-wise Net Sharpe

Model	Early	Middle	Recent	Average
Linear	1.06	0.54	2.41	1.34
Momentum	-2.57	-0.82	-1.38	-1.59
Reversal	1.10	-1.01	-0.14	-0.02
MLP	1.25	1.32	2.69	1.75
MLP_GAT	3.26	0.45	**3.27**	2.33
DMFM	**3.31**	**1.90**	2.99	**2.73**

Table 4는 테스트 구간을 EARLY, MIDDLE, RECENT의 세 하위 기간으로 분할하여 Net

Sharpe Ratio를 비교한 결과를 보여준다. 이 분석은 모델 성과가 특정 시장 국면에 편중되어 있는지를 점검하기 위한 목적에서 수행되었다.

DMFM은 모든 기간에서 양(+)의 Sharpe Ratio를 기록하였으며, 특히 EARLY(3.31)와 RECENT(2.99) 구간에서 가장 높은 성과를 보였다. 이는 DMFM이 학습 초반 데이터에 과적합되거나 최근 구간에만 특화된 모델이 아니라, 서로 다른 시장 환경에서도 안정적인 성과를 유지함을 의미한다.

반면, Momentum 전략은 모든 기간에서 일관되게 음의 Sharpe Ratio를 기록하였으며, Reversal 전략 역시 기간별 성과 변동성이 크게 나타났다. MLP 및 MLP+GAT은 특정 구간에서는 양호한 성과를 보였으나, 구간 간 변동성이 상대적으로 크게 관측되었다. 이러한 결과는 구조적 정보를 제거하지 않은 단순 비선형 모델의 한계를 시사한다.

IV-3. Cumulative Return Analysis

Figure 1
Period-wise Cumulative Return

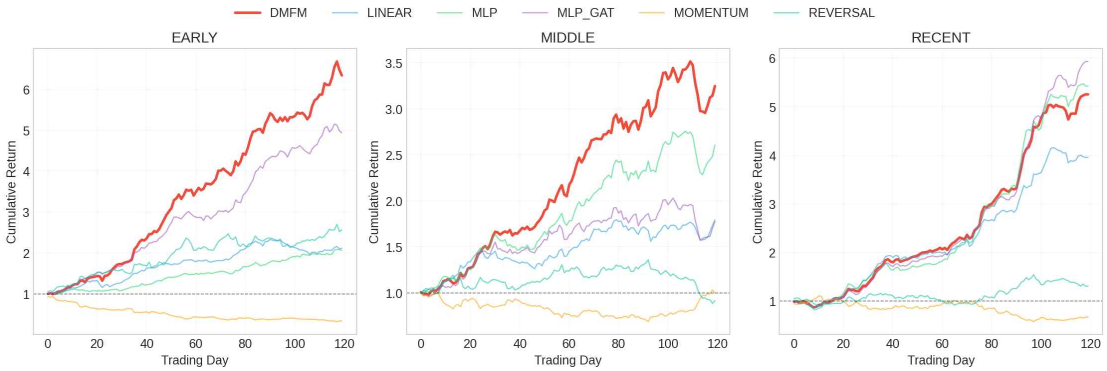


Figure 1에서 볼 수 있는 기간별 누적 수익 곡선에서도 DMFM의 성과 우위는 명확하게 확인된다. EARLY, MIDDLE, RECENT 모든 구간에서 DMFM의 누적 수익 곡선은 비교 모델 대비 더 가파르고 안정적인 상승 경로를 보인다.

특히 EARLY 및 MIDDLE 구간에서는 MLP+GAT이 일정 수준의 성과를 보이지만, 변동성이 상대적으로 크게 나타나는 반면, DMFM은 상대적으로 작은 조정과 함께 꾸준한 우상향 패턴을 유지한다. RECENT 구간에서도 DMFM은 시장 변동성이 확대되는 환경 속에서도 안정적으로 초과 수익을 창출하였다.

IV-4. Multi-metric Comparision

Figure 2

Model Performance Radar Chart

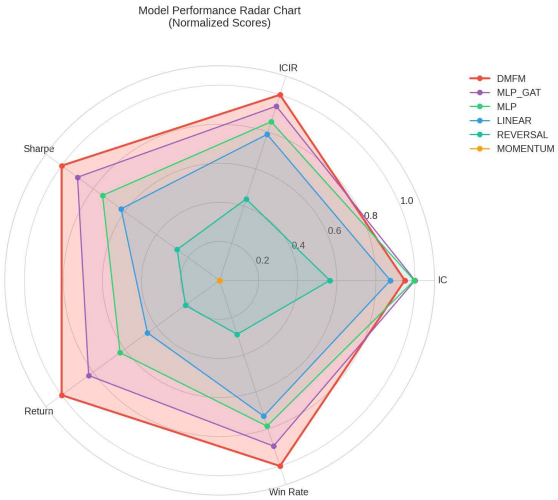


Figure 2는 IC, ICIR, Sharpe, Return, Win Rate를 정규화하여 모델 간 성과를 종합적으로 비교한 결과를 시각적으로 보여준다. DMFM은 모든 지표에서 균형 잡힌 확장된 면적을 형성하며, 특정 지표에만 강점이 집중되지 않는 특성을 보인다.

이는 DMFM이 단순히 수익률 극대화에만 치중한 모델이 아니라, 예측 정확도, 성과 안정성, 리스크 관리 측면을 동시에 고려한 종합적 투자 모델임을 시사한다.

IV-5. Discussion

종합하면, 본 실험 결과는 그래프 구조 자체보다도, 해당 구조로부터 발생하는 공통 요인을 제거하는 중립화 메커니즘이 성과 개선의 핵심 요소임을 보여준다. DMFM은 산업 및 시장 수준의 영향을 단계적으로 분리함으로써, 보다 순수한 종목 고유 알파를 추출할 수 있었고, 이는 높은 Sharpe Ratio와 안정적인 누적 수익으로 이어졌다.

이러한 결과는 DMFM이 다양한 시장 국면에서도 실무적으로 활용 가능한 알파 생성 모델로서 경쟁력을 가짐을 뒷받침한다.

V. Conclusion

본 연구는 기존에 제안된 Deep Multi-Factor Model (DMFM)을 한국 주식 시장(KOSPI)에 적용하여, 해당 모델의 일반화 가능성과 실무적 유효성을 실증적으로 검증하였다. 전통적인 선형 팩터 모델과 신경망 기반 베이스라인 모델들은 팩터와 수익률 간의 비선형 관계를 부분적으로 포착할 수 있으나, 산업 및 시장 수준에서 발생하는 구조적 공통 요인을 충분히 분리하지 못한다는 한계를 지닌다. 이에 본 연구는 DMFM의 핵심 구조인 산업 및 시장 중립화(neutralization)가 한국 시장에서도 실질적인 성과 개선으로 이어지는지를 중심적으로 분석하였다.

실험 결과, DMFM은 평균 IC 수준에서 기존 비선형 모델들과 유사한 예측 정확도를 유지하면서도, ICIR, Net Sharpe Ratio, 연환산 수익률, Win Rate 등 대부분의 핵심 성과 지표에서 일관되게 우수한 성과를 기록하였다. 특히 거래 비용을 반영한 기준에서 Net Sharpe Ratio 2.73, 연환산 수익률 52.2%를 달성하였으며, 최대 낙폭 또한 상대적으로 낮게 유지되었다. 이는 DMFM이 단순히 평균적인 예측력을 개선하는 데 그치지 않고, 시간에 따른 성과의 안정성과 리스크 관리 측면에서도 강점을 지님을 의미한다.

기간별 성과 분석에서도 DMFM은 EARLY, MIDDLE, RECENT 모든 구간에서 양(+)의 Sharpe Ratio를 기록하며, 특정 시장 국면에 편중되지 않은 견고한 성과 구조를 보여주었다. 반면, 그래프 구조를 활용하되 중립화 과정을 포함하지 않은 MLP+GAT 모델은 일부 구간에서 높은 성과를 보였으나, 전반적인 안정성 측면에서는 DMFM에 비해 한계를 드러냈다. 이러한 결과는 그래프 기반 구조 그 자체보다도, 해당 구조로부터 추정된 공통 요인을 제거하는 과정이 성과 개선의 핵심 요소임을 시사한다.

종합하면, 본 연구는 DMFM이 중국 시장에 국한된 모델이 아니라, 산업 구조와 시장 특성이 상이한 한국 주식 시장에서도 안정적인 알파를 생성할 수 있음을 실증적으로 확인하였다. 이는 DMFM이 향후 다양한 국가 및 자산군으로 확장 적용될 수 있는 잠재력을 지님을 시사하며, 딥러닝 기반 팩터 모델 연구에서 구조적 중립화의 중요성을 재확인하는 결과로 해석할 수 있다. 향후 연구에서는 더 세분화된 산업 구조, 동적 그래프 구성, 혹은 장기 투자 지평선으로의 확장을 통해 DMFM의 활용 가능성을 추가적으로 탐구할 수 있을 것이다.

Appendix. KOSPI 지수 Buy & Hold와 DMFM 전략 비교 실험

Table

Comparison with Market Index

항목	DMFM	KOSPI BUY&HOLD
Annual Return	52.2%	6.3%
Annaul Volatility	19.1%	16.6%
Net Sharpe	2.73	0.38
Max DrawDown	-24.7%	-43.9%
Win Rate	66.7%	53.5%

Note. 동일 기간에서 같은 조건으로 실험됨.